



SKILL PARA CLAUDE CODE

Raio-X de Custo

A fatura que ninguém abriu

Você sabe quanto custou construir. Sabe quanto custa manter? A maioria descobre quando a fatura chega.

Sistema com dívida técnica custa em média 300% mais para manter em 18 meses.

Custo não medido é Dívida: cresce todo mês que ninguém olha, e fica mais caro de corrigir com o tempo.

Palavra-chave desta skill: **FATURA**

Como a skill trabalha

A skill mapeia tudo que custa por uso no projeto — chamadas de LLM, embeddings, storage, serviços de terceiro — e registra o que dispara cada uma. Depois verifica 8 pontos onde o dinheiro costuma vazar e estima o custo por request, por usuário e por mês. Toda estimativa vem com a premissa declarada: número sem premissa é chute, e ela não faz isso.

Crítico

São os três que transformam um erro pequeno em fatura grande. Nenhum aparece até o fechamento do mês.

Chamada de LLM sem max_tokens

Procura `messages.create`, `chat.completions` e `generateText` sem teto de tokens na resposta.

Custa: a resposta que devia ter 200 tokens pode sair com 4.000 — vinte vezes o previsto, na mesma chamada.

Retry sem limite ou sem backoff

Localiza blocos de `retry`, `loops while` e `catch` que refazem a chamada, e verifica se há teto de tentativas e espera crescente entre elas.

Custa: cada tentativa é cobrada como chamada nova. Um erro que persiste vira loop pago rodando sozinho.

Rota cara sem autenticação e sem rate limit

Cruza as rotas públicas com as que chamam serviço pago.

Custa: um script roda sua cota inteira numa madrugada, e você descobre quando o serviço para de responder.

Alto

Estes não quebram nada. Só cobram mais do que precisavam, todo dia, em silêncio.

Contexto reenviado inteiro a cada mensagem

Verifica se o histórico de conversa cresce sem corte, sem janela deslizante nem resumo do que ficou para trás.

Custa: a mensagem número 20 custa vinte vezes a primeira. O custo cresce dentro da mesma sessão, sem ninguém mexer em nada.

Sem cache em pergunta repetida

Procura se existe cache por hash da entrada, ou prompt caching quando o provedor oferece.

Custa: em FAQ e busca costuma ser a maior fatia da fatura: você paga de novo pela resposta que já tinha.

Modelo grande em tarefa pequena

Identifica onde o modelo mais caro é usado para classificar, extrair campo ou decidir sim/não.

Custa: até dez vezes o necessário. O modelo pequeno resolve tarefa mecânica pelo mesmo resultado.

Médio

Pouco por vez, muito no acumulado — e o segundo é o que impede você de enxergar todos os outros.

Embedding recalculado sem necessidade

Verifica se a reindexação processa o corpus inteiro quando só uma parte mudou.

Custa: você paga para reprocessar o que já estava indexado, toda vez que qualquer coisa muda.

Sem registro de consumo por request

Confere se input_tokens e output_tokens são registrados a cada chamada.

Custa: você não descobre o vazamento. Descobre a fatura — e sem log não dá para saber de onde veio.

Como usar

1. Baixe o arquivo da skill no link abaixo.
2. Mande o arquivo para o seu Claude Code e diga: *"instala essa skill pra mim"*. Ele resolve o resto.
3. Dentro da pasta do seu projeto, peça: *"raio-x de custo nesse projeto"*.
4. Leia o laudo. Cada ponto aberto tem arquivo, linha e o que fazer.

<https://redpro.com.br/redreply/skills/raio-x-custo.md>